

Inteligência Artificial – Aprendizagem de Máquina

(Introdução - Aplicações / Pesquisa)

Prof. Dr. Alceu Britto
PUCPR

Agenda

➤ **Parte 1 (Teoria)**

- Introdução à Machine Learning
- Impactos positivos na sociedade
- Efeitos colaterais
- Projetos de pesquisa no PPGIa (PUCPR)

➤ **Parte 2 (Prática)**

- Abordagem Supervisionada
- Tarefa de Classificação
- Ferramentas: Python, Numpy e Scikit Learn
- Ambiente: Google Colab

IA, do que se trata?

“Disciplina da Ciência da Computação cujo objetivo é desenvolver **soluções tecnológicas que simulam o raciocínio humano**, ou seja, a inteligência que é característica dos seres humanos.”

“Máquinas podem pensar?” - **Alan Turing** (1950)


IA considerada ciência em 1956
(Dartmouth College, USA).



Onde se deseja chegar?

- Criação de soluções inteligentes autônomas.
 - Resolvem qualquer problema.
 - Aprendem sozinhas.
 - Sentem emoções.

- Estado da arte
 - Há soluções que já superaram o ser humano em tarefas específicas em diferentes áreas.



Cena do filme Ex-machina

Alguns Temas Importantes na Área de IA



Temas Emergentes


Análise de Grandes
Volumes de Dados
(**Big Data Analytics**)

Aprendizagem Profunda
(**Deep Learning**)

Ciência de Dados
(**Data Science**)


Qual relação entre estes temas?

- IA (Artificial Intelligence)
- ML (Machine Learning)
- DL (Deep Learning)
- DS (Data Science)



Aprendizagem de Máquina (AM), do se trata?

- ❑ Ramo da **Inteligência Artificial**
- ❑ Solução de um problema aprendida **a partir de dados** (amostras ou exemplos).
- ❑ Mínimo de intervenção humana.
- ❑ Uso de **técnicas de indução**
- ❑ **Modelos cognitivos** - Dados (commodity do século XXI) transformados em conhecimento.



Aprendizagem de Máquina (AM), quais as abordagens?


- ☐ Não supervisionada
 - não requer dados rotulados
- ☐ Supervisionada
 - requer dados rotulados
- ☐ Semi-supervisionada
 - alternativa quando não temos dados rotulados em quantidade suficiente
- ☐ Por reforço
 - não precisa de dados de treinamento.



Aprendizagem de Máquina (AM) - Abordagem Não Supervisionada

Tarefa principais:

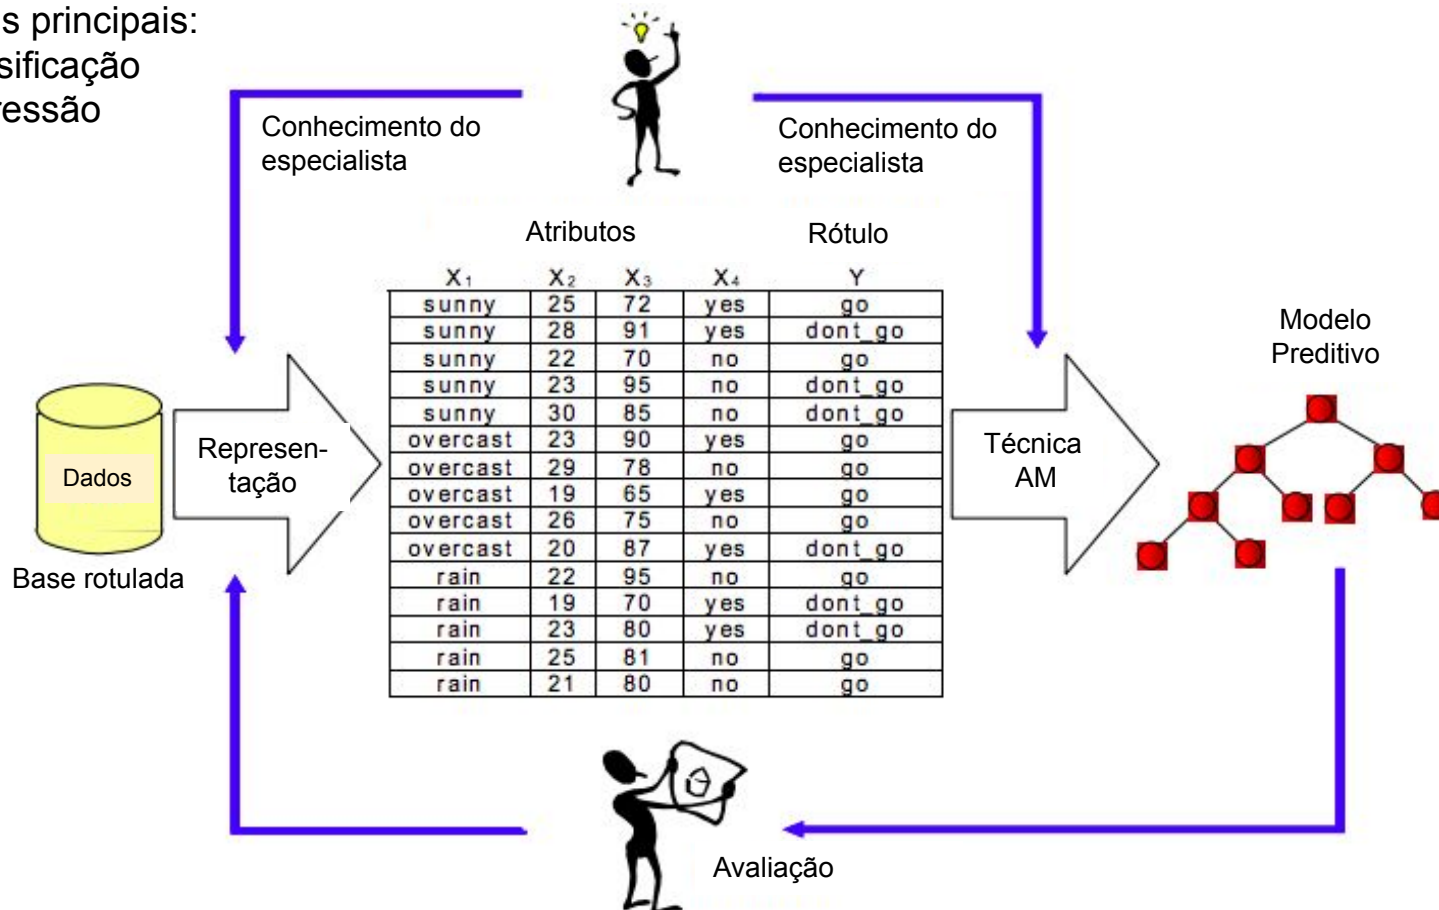
- Agrupamento
- Associação



Aprendizagem de Máquina (AM) – Abordagem Supervisionada

Tarefas principais:

- Classificação
- Regressão

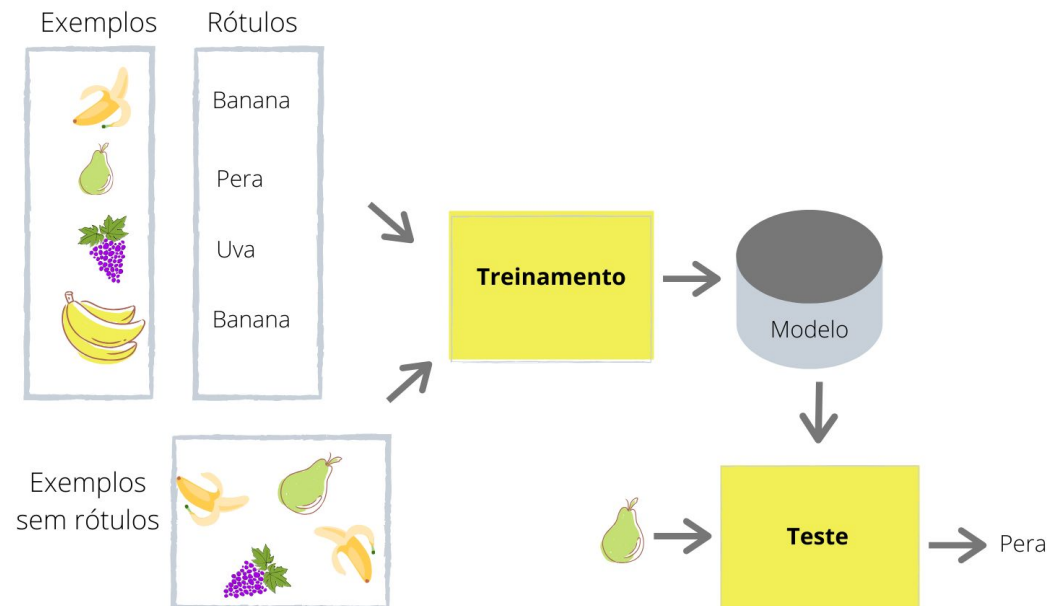


Aprendizagem de Máquina (AM) – Abordagem Semi-supervisionada

Tarefas principais:

- Classificação
- Regressão

Aprendizagem Semi-supervisionada



Aprendizagem de Máquina (AM) – Abordagem por Reforço

Tarefas principais:

- Games
- Robótica

Aprendizagem por Reforço



- Não precisa de base de dados
- Precisa de um esquema de interação com ambiente.
- Recompensa/penalidade

Impactos positivos na sociedade

Google creates new self-driving car company



Dave Lee
North America technology reporter

🕒 13 December 2016

f 🗨️ 🐦 ✉️ Share



GETTY IMAGES

Google has a car that operates without the need for a steering wheel

Setor de Transportes:
veículos autônomos



Impactos positivos na sociedade

Setor do Comércio/Serviços:
robôs (chatbots)



How AI is disrupting the role of call centres and call centre staff

Artificial intelligence could eliminate many white-collar jobs in coming decades. Its effects are already being felt in the call centre industry, but there is still no substitute for the human touch



Lara Ponomareff
CEB

One of the most hotly debated subjects at this year's [World Economic Forum](#) in Davos concerned the [risks posed by technology to jobs, political stability and cyber security](#).

Impactos positivos na sociedade

Artificial intelligence that can teach? It's already happening

f Share on Facebook

Share on Twitter



ABC Science By Carl Smith for the Science Show

Updated 15 June 2018 at 10:10 pm

First posted 15 June 2018 at 5:04 pm



Educação: ensino
customizado para
cada aluno

Impactos positivos na sociedade

China embraces artificial intelligence-driven agriculture, emerges as global technology hothouse

Craig Moran | Real Clear Science | July 12, 2018

Agricultura: uso da
precisão no cultivo.



Image credit: ADC Forum

Impactos positivos na sociedade

How disruptive start-ups are tapping into robotics and artificial intelligence

Sangeeta Das Co-founder, Collaborative Intelligence, said 'We are largely in the robotics space, artificial intelligence and cybersecurity'.

Last Published: Tue, Nov 06 2018. 12 02 PM IST

✉ Livemint

Enter email for newsletter

Sign Up




Photo: iStock

MORE FROM COMPANIES »

- ▶ **Aircel Maxis case: Yes Bank wants RBI to decide on Ashok Chawla continuing as chairman**
- ▶ **Everstone Capital to overhaul private equity business in restructuring exercise**
- ▶ **Duff and Phelps's Varun Gupta: Interest in India's stressed assets would go up meaningfully**
- ▶ **Health tech startup funding hits all-time high of \$510 million in 2018**

Empreendedorismo:
start-ups têm como
base inovações
usando IA

Efeitos colaterais na sociedade

- Éticos e morais (*Social Credit System*)



Muito importante a definição de **Políticas Nacionais** com relação à IA.

Isto já está acontecendo nos EUA, Canadá, Alemanha, França e Japão.

- Desemprego



Projetos de Pesquisa Realizados no PPGIa (PUCPR)

- Reconhecimento de expressões faciais
- Determinação da idade através da face
- Classificação de vaga em estacionamento
- Reconhecimento de gestos
- Classificação de gêneros musicais

Fusion of feature sets and classifiers for facial expression recognition

Thiago H.H. Zavaschi^a, Alceu S. Britto Jr.^a, Luiz E.S. Oliveira^b, Alessandro L. Koerich^{a,b,*}

^a Pontifical Catholic University of Paraná (PUCPR), R. Imaculada Conceição, 1155, Curitiba, PR 80215-901, Brazil

^b Federal University of Paraná, R. Cel. Francisco H. dos Santos, 100, Curitiba, PR 81531-990, Brazil



Table 4

Comparison with different approaches on JAFFE database.

Reference	Accuracy (%)	Features
Zhang et al. (1998)	90.1	Geometry and Gabor
Bashyal and Venayagamoorthy (2008)	90.2	Gabor and LVQ
Koutlas and Fotiadis (2008)	92.3	Gabor filters
Liu and Wang (2006)	92.5	Gabor filters
Oliveira et al. (2011)	94.0	2DPCA with feature selection and SVM
Shih et al. (2008)	94.1	2D-LDA and SVM
Liao et al. (2006)	94.5	LPB, Tsallis entropies, global appearance
Cheng et al. (2010)	95.2	Gaussian process
Zhi and Ruan (2008)	95.9	2D locality preserving projections
Proposed approach	96.2	Ensemble based on Gabor and LBP



A flexible hierarchical approach for facial age estimation based on multiple features



Jhony K. Pontes^a, Alceu S. Britto Jr.^b, Clinton Fookes^a, Alessandro L. Koerich^{c,*}

^a Image and Video Research Laboratory, Queensland University of Technology, Brisbane, Queensland, Australia

^b Postgraduate Program in Computer Science, Pontifical Catholic University of Paraná, Curitiba, Paraná, Brazil

^c Department of Software and IT Engineering, École de Technologie Supérieure, Montréal, Québec, Canada

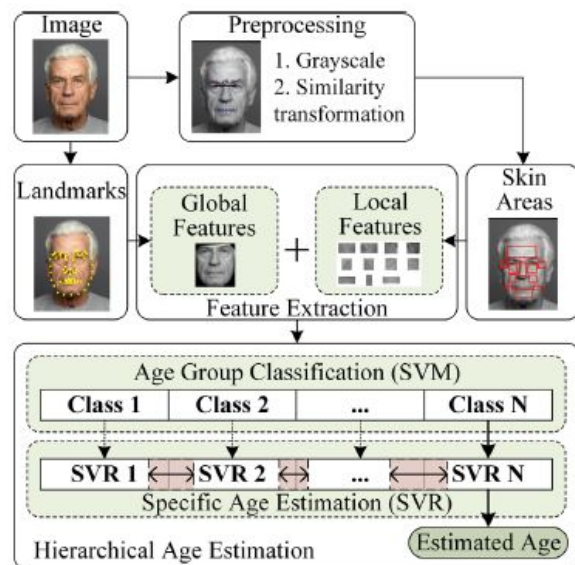


Fig. 1. An overview of the proposed age estimation approach.

Table 9

Comparison of the proposed approach to the previous works reported on the FG-NET Aging dataset.

Methods of age estimation	MAE	Methods of age estimation	MAE
WAS [29]	8.06	Duong et al. [14]	4.74
AGES [18]	6.77	Choi et al. [9]	4.65
RUN [42]	5.78	PLO [31]	4.82
Ranking [41]	5.33	CA-SVR [7]	4.67
LARR [19]	5.07	HC-SVR [32]	5.28
SVR [19]	5.66	ST+CSOHR [5]	4.70
Luu et al. [33]	4.37	Human age estimation	6.52
MTWGP [44]	4.83	Flexible overlapped & AAM + LPQ_{7×7}	4.50
OHRank [6]	4.85	Flexible overlapped & AAM + LPQ_{7×7} (LOPO)	4.78




Fig. 2. Sample images from FG-NET: (a) grayscale conversion and the 68 landmarks and (b) after normalization and the eleven skin areas.



Music Genre Classification using Dynamic Selection of Ensemble of Classifiers

- 10 classes base LMD (Latin Music Database)




Figure 1. Feature extraction from 3 segments of the music signal adapted from [2].

TABLE V. BEST RESULTS OF THE DYNAMIC SELECTION METHOD AND THE CORRESPONDING K VALUE

Selection scheme	# of classifiers selected	# of votes	Accuracy (%)
Experiment 1 (E1) Oracle = 100%			
KE ($k = 1$)	72	72	59.66
KU ($k = 10$)	249	709	70.31
Experiment 2 (E2) Oracle = 100%			
KE ($k = 1$)	43	43	57.02
KU ($k = 13$)	143	573	64.94



An HMM-based Gesture Recognition Method Trained on Few Samples

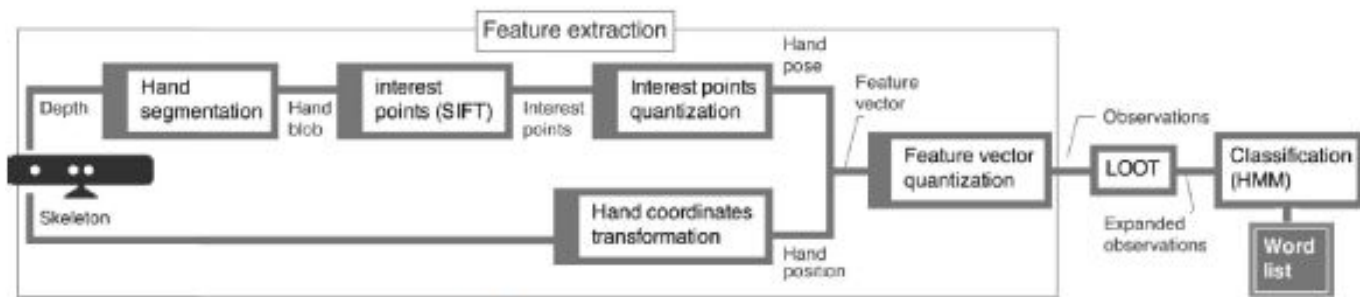


Fig. 2: Overview of the proposed method

# of training samples (for each word)	LRM without LOOT			LRM with LOOT			LRE with LOOT		
	top1	top2	top3	top1	top2	top3	top1	top2	top3
1	23.7	24.8	25.9	23.7	25.4	26.5	29.0	29.6	33.3
3	24.3	25.9	28.1	25.9	28.7	30.3	46.9	49.4	50.6
5	34.8	41.4	53.5	37.5	43.0	57.4	59.9	64.8	66.0
10	61.3	76.8	78.4	63.5	77.9	79.0	85.0	87.7	90.7
14	66.3	81.2	83.9	69.0	84.5	86.1	88.5	98.8	98.8
17	72.3	83.9	88.4	76.2	87.2	92.8	91.2	100.0	100.0



PARTE 2

APRENDIZAGEM SUPERVISIONADA

- Modelos Preditivos => Tarefas Classificação ou Regressão
 - Classificação => modelo cuja saída é um valor discreto (saída categórica)
 - Exemplo: classificar uma pessoa a partir da imagem da face em faixas etárias (criança, jovem, adulto, idoso);
 - Regressão => modelo cuja saída é um valor contínuo.
 - Exemplo: estimar a idade de uma pessoa a partir da imagem da face.

APRENDIZAGEM SUPERVISIONADA

- Conceitos Básicos Importantes

- **Base de dados:** composta por instâncias.
- **Instância:** tupla (X, y) , onde X é um conjunto de atributos (ou features) e y é o atributo alvo (aquele que será calculado, predito).
- **Função alvo:** $y=f(X)$, representa uma hipótese de solução para o problema em mãos (um modelo preditivo).
- **Treinamento:** indução do modelo a partir de uma porção de dados disponível, chamada de base de treinamento.
- **Testes:** avaliação do modelo em base distinta da usada no treinamento. Objetivo: medir capacidade de generalização.
- **Indutor:** algoritmo utilizado na geração do modelo.

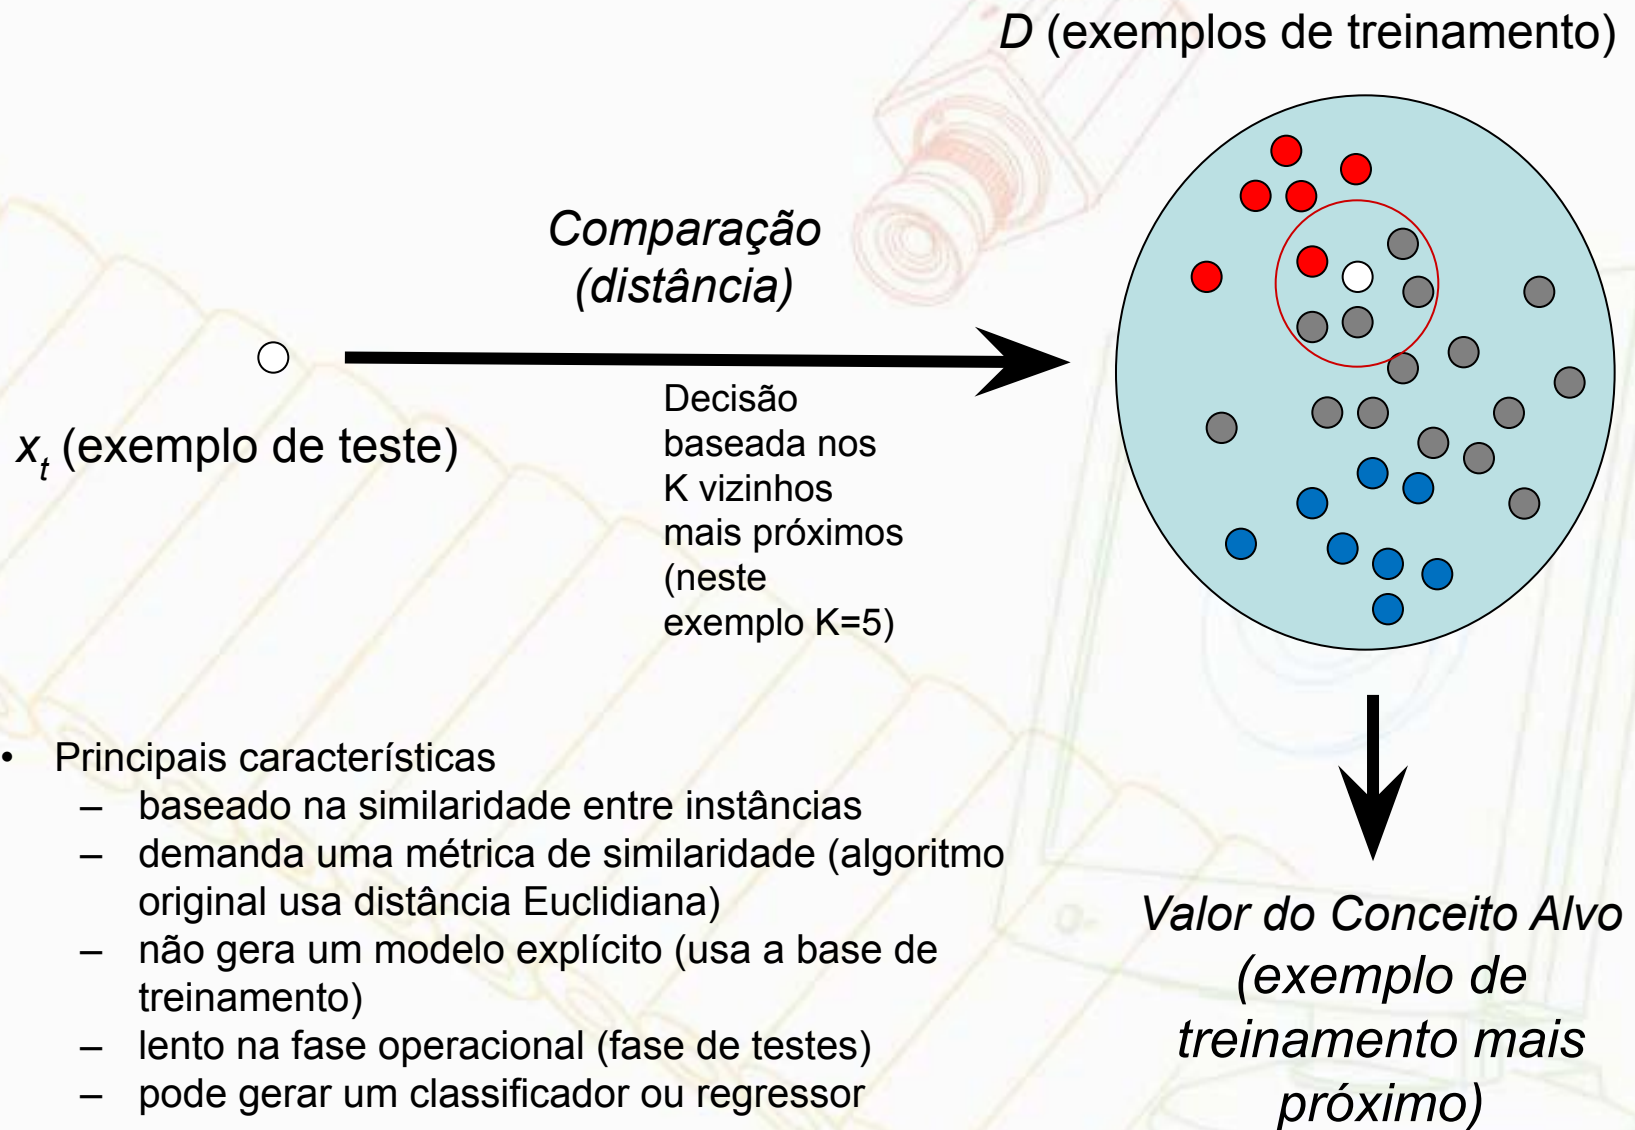
	X_1	X_2	...	X_m	Y
T1	x_{11}	x_{12}	...	x_{1m}	y_1
T2	x_{21}	x_{22}	...	x_{2m}	y_2
...
Tn	x_{n1}	x_{n2}	...	x_{nm}	y_n

Aprendizagem de Máquina (AM) – Classificação

- Tarefa supervisionada (demanda dados rotulados)
 - Há diferentes técnicas na AM – diferem na teoria utilizada e modelos gerados.


Teoria	Técnica de exemplo	Modelo
Entropia e ganho de informação	Árvores de Decisão	<ul style="list-style-type: none"> - Modelo é uma Árvore - Caixa branca (muito usado na Medicina e Direito)
Similaridade entre instâncias do problema	K-vizinhos mais próximos	<ul style="list-style-type: none"> - Não gera modelo explícito (não há um algoritmos de treinamento) - Lento na fase operacional (testes)
Probabilidades, Teorema de Bayes	Naive Bayes	<ul style="list-style-type: none"> - Modela probabilidades a priori e condicional entre atributos de entrada e as classes. Assume atributos de entrada independentes.
Conexionismo, simulação do cérebro e neurônios, otimização	Redes Neurais Artificiais	<ul style="list-style-type: none"> - Modelo é um grafo onde vértices são neurônios e arestas as conexões (sinapses). - Considerados caixa-preta, ou seja, não fornecem explanação para a resposta dada.
Vetores de suporte, kernels, otimização, lagrange.	Máquinas de Vetor de Suporte (SVM, Support Vector Machines)	<ul style="list-style-type: none"> - Modelo composto por vetores de suporte (instâncias do problema) usadas para definir hyperplano que separa as classes do problema.

Técnica: KNN (K-Nearest Neighbors)



Avaliação de Classificadores:

- Holdout



Fonte: O autor

Comum: (X=60% Y=40%) ou : (X=70% Y=30%)

- Validação Cruzada

Figura 2 - Esquema Validação Cruzada (5-Fold)

	Base de Dados		
Fold 1	TR		TE
Fold 2	TR		TE
Fold 3	TR	TE	TR
Fold 4	TR	TE	TR
Fold 5	TE	TR	

Avaliação de Classificadores:

- Matriz de confusão (problema binário - duas classes)

Classe Predita (saída do classificador)			
Classe real (rótulo)		(+)	(-)
	(+)	VP	FN
	(-)	FP	VN

- VP (Verdadeiro Positivo): corretamente classificados
- VN (Verdadeiro Negativo): corretamente classificados
- FP (Falso Positivo): erroneamente classificados como positivos
- FN (Falso Negativo): erroneamente classificados como negativos

- Métricas

- Taxa de acerto (Acurácia) = $(VP+VN) / (VP+VN+FP+FN)$
- Precisão (Precision): $P = VP / (VP+FP) \Rightarrow$ Um modelo que não produz falso positivo (FP) tem precisão igual a 1. (quantos itens selecionados são relevantes)
- Revocação (Recall): $R = VP / (VP + FN) \Rightarrow$ Um modelo que não produza falso negativo (FN) tem revocação igual a 1. (quantos item relevantes foram selecionados)
- F-measure: $2/(1/P+1/R)$

Avaliação de Classificadores:

- Matriz de confusão (problema com múltiplas classes)

True Class	airplane	923	4	21	8	4	1	5	5	23	6
	automobile	5	972	2					1	5	15
	bird	26	2	892	30	13	8	17	5	4	3
	cat	12	4	32	826	24	48	30	12	5	7
	deer	5	1	28	24	898	13	14	14	2	1
	dog	7	2	28	111	18	801	13	17		3
	frog	5		16	27	3	4	943	1	1	
	horse	9	1	14	13	22	17	3	915	2	4
	ship	37	10	4	4		1	2	1	931	10
	truck	20	39	3	3			2	1	9	923
		Predicted Class									
		airplane	automobile	bird	cat	deer	dog	frog	horse	ship	truck

Soma da diagonal => Total Acertos.

Soma dos elementos da matriz => Total Amostras de Teste.

Acurácia = (Total Acertos / Total Amostras de Teste).

Precisão por classe: Valor da diagonal / Soma da coluna.

Revocação: Valor da diagonal / Soma da linha.

Atenção: cuidado com bases desbalanceadas (não é o caso aqui)


Bases desbalanceadas não se usa acurácia.

- Diagonal estão os acertos.
- Demais posições as confusões entre classes (erros).

Exemplo: Classificador de dígitos manuscritos


□ Base de Dados (*Digits dataset*)

- https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_digits.html
- Número de classes: 10
- Exemplos por classe: ~180
- Total de exemplos: 1797



□ Esquema Representação do Problema

- Vetor de características: 64 atributos inteiros
- Atributos (*Features*): valores inteiros na faixa (0-16) - tons de cinza.



16	15	9	...	8	10	12	13
1	2	3	...	62	62	63	64

Imagem 8x8
pixels

vetor com 64 valores inteiros

Exemplo => Treinamento de um Modelo Preditivo (neste caso um classificador).

□ Passos

- 1) Escolha a técnica de AM a ser utilizada.
- 2) Carregue a base de dados.
- 3) Organize o protocolo experimental
 - a) divida a base em conjunto(s) de treinamento e teste;
 - b) base pequena, recomenda-se validação cruzada.
- 4) Criar o modelo preditivo (neste exemplo KNN).
- 5) Treinar o modelo (fase de treinamento).
- 6) Avaliar o modelo (fase de testes).
 - a) Calcular a taxa de acerto (acurácia neste exemplo)
 - b) Calcular a matriz de confusão. Usada em tarefas de classificação para mostrar a confusão entre classes.
- 7) Analisar os erros do modelo. Isto é importante para entender como aprimorá-lo.

Exemplo: Classificação de dígitos manuscritos

☐ Base de dados

- https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_digits.html

➤ Script Treinamento e Avaliação usando HOLDOUT

- Vamos construir juntos

☐ Script Treinamento e Avaliação usando Validação Cruzada

- Vamos construir juntos

☐ Objetivo: treinar e avaliar diferentes modelos preditivos

☐ Link para Google Colab

- <https://colab.research.google.com/notebooks/welcome.ipynb?hl=pt-BR>

REFERÊNCIAS

- Duda R., Hart P., Stork D. *Pattern Classification 2ed.* Willey Interscience, 2002. Capítulo 8.
- Mitchell T. *Machine Learning.* WCB McGraw–Hill, 1997. Capítulo 3.
- Quinlan, J.R.: C4.5: Programs for Machine Learning. Morgan Kauffman, 1993.
- Russel S. J., Norvig P., Inteligência Artificial, 2a. Edição, Editora Campus, 2004.
- Faceli, K., Lorena, A.C., Gama, J. & Carvalho, A.C.P.L.F, Inteligência Artificial – Uma Abordagem de Aprendizado de Máquina, LTC, 2011.
- Bishop, C. M. Pattern Recognition and Machine Learning. Springer, 2006

Obrigado !

Perguntas?